

Basic Signal and Image Processing Knowledge (3)

基礎信號與影像處理知識(三)

丁建均 教授

國立台灣大學電信工程學研究所

2019年8月15日

Image Processing 基礎知識 (2)

- (1) Matlab 寫程式的原則
- (2) Image Fusion by the Fourier Transform
- (3) Morphology
- (4) Equalizer for Images
- (5) Principal Component Analysis (PCA) and Singular Value Decomposition (SVD)

(1) Matlab 寫程式的原則

一、各種程式語言寫程式共通的原則

- (1) 能夠不在迴圈內做的運算，則移到迴圈外，以節省運算時間
- (2) 寫一部分即測試，不要全部寫完再測試 (縮小範圍比較容易 debug)
- (3) 先測試簡單的例子，成功後再測試複雜的例子

二、Matlab 寫程式特有的技巧

- (1) 迴圈能避免就儘量避免
- (2) 儘可能使用 Matrix 及 Vector operation

Example: 由 1 加到100，用 Matlab 一行就可以了

```
sum([1:100])
```

完全不需迴圈



三、一些重要的 Matlab 指令

(1) **function**: 放在第一行，可以將整個程式函式化

(2) **tic, toc**: 計算時間

tic 為開始計時，toc 為顯示時間

(3) **find**: 找尋一個 vector 當中不等於 0 的 entry 的位置

範例：find([1 0 0 1]) = [1, 4]

find(abs([-5:5])<=2) = [4, 5, 6, 7, 8]

(因為 abs([-5:5])<=2 = [0 0 0 1 1 1 1 1 0 0 0])

(4) **'**: Hermitian (transpose + conjugation), **.'**: transpose

(5) **imread**: 讀圖，**image, imshow, imagesc**: 將圖顯示出來，

(註：較老的 Matlab 版本 imread 要和 double 並用

A=double(imread('Lena.bmp'));

(6) **imwrite**: 製做圖檔



- (7) `xlsread`: 由 Excel 檔讀取資料
- (8) `xlswrite`: 將資料寫成 Excel 檔
- (9) `aviread`: 讀取 video 檔
- (10) `dlmread`: 讀取 *.txt 或其他類型檔案的資料
- (11) `dlmwrite`: 將資料寫成 *.txt 或其他類型檔案



(2) Image Fusion by the Fourier Transform


2-D Discrete Fourier Transform (2-D DFT)

$$X[p, q] = \sum_{m=0}^{M-1} \sum_{n=0}^{N-1} x[m, n] e^{-j \frac{2\pi m p}{M}} e^{-j \frac{2\pi n q}{N}}$$

$$x[m, n] = \frac{1}{MN} \sum_{p=0}^{M-1} \sum_{q=0}^{N-1} X[p, q] e^{j \frac{2\pi m p}{M}} e^{j \frac{2\pi n q}{N}}$$



FT




Using the gray level to show the intensity

```
image(.....)  
colormap(gray(256))
```




Low Frequency Part: Signal


High Frequency Part: Edge and Noise



Lowpass output




Passband: $|f_x| + |f_y| \leq N/30$




Passband: $|f_x| + |f_y| \leq N/10$



Highpass output




Passband: $|f_x| + |f_y| > N/30$



Passband: $|f_x| + |f_y| > N/10$



A 圖低頻
加 B 圖高頻



http://cvcl.mit.edu/hybrid_gallery/monroe_einstein.html

(3) Morphology

(3-1) Erosion

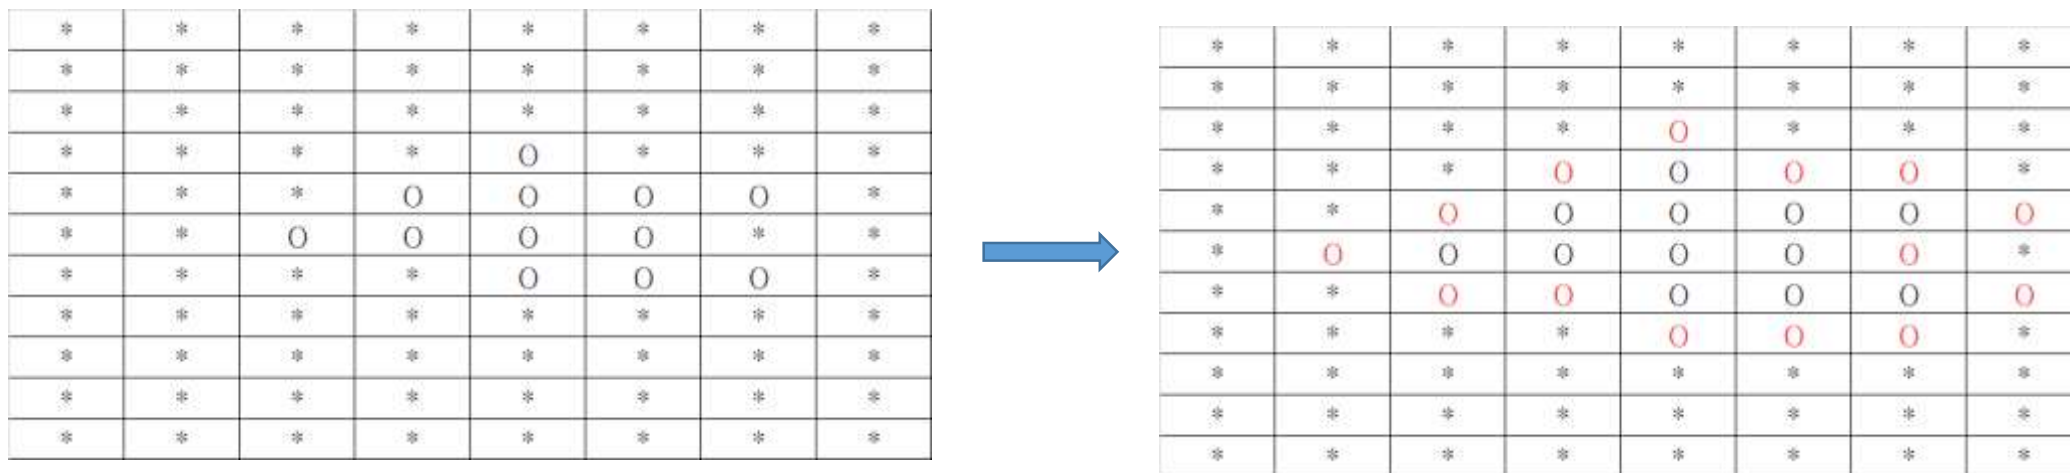
*	*	*	*	*	*	*
*	*	*	*	0	*	*
*	*	0	0	0	0	*
*	0	0	0	0	0	*
*	0	0	0	0	0	*
*	0	0	0	0	0	*
*	*	0	0	0	*	*
*	*	*	0	*	*	*
*	*	*	*	*	*	*



*	*	*	*	*	*	*
*	*	*	*	*	*	*
*	*	*	*	0	*	*
*	*	0	0	0	*	*
*	*	0	0	0	*	*
*	*	0	0	0	*	*
*	*	*	0	*	*	*
*	*	*	*	*	*	*
*	*	*	*	*	*	*

$$A[m,n] = A[m,n] \& A[m-1,n] \& A[m+1,n] \& A[m,n-1] \& A[m,n+1]$$

(3-2) Dilation



$$A[m,n] = A[m,n] \vee A[m-1,n] \vee A[m+1,n] \vee A[m,n-1] \vee A[m,n+1]$$

Erosion for a Non-binary Image


$$A[m,n] = \min \{ A[m,n], A[m-1,n], A[m+1,n], A[m,n-1], A[m,n+1] \}$$

Dilation for a Non-binary Image


$$A[m,n] = \text{Max} \{ A[m,n], A[m-1,n], A[m+1,n], A[m,n-1], A[m,n+1] \}$$

(3-3) Closing (Hole Filling)


closing = dilation k times + erosion k times



dilation 3 times



then erosion 3 times






(3-4) Opening

opening = erosion k times + dilation k times

erosion 3 times

then dilation 3 times



(4) Equalizer for Images

$$y[m, n] = x[m, n] * k[m, n] \quad \text{Equalizer: } H(F_x, F_y) = \frac{1}{K(F_x, F_y)}$$

Problem: If the system is interfered by noise $noise[m, n]$

$$y[m, n] = x[m, n] * k[m, n] + noise[m, n]$$

$$Y(F_x, F_y) = X(F_x, F_y)K(F_x, F_y) + Noise(F_x, F_y)$$

$$\begin{aligned} H(F_x, F_y)Y(F_x, F_y) &= X(F_x, F_y)H(F_x, F_y)K(F_x, F_y) + H(F_x, F_y)Noise(F_x, F_y) \\ &= X(F_x, F_y) + \frac{Noise(F_x, F_y)}{K(F_x, F_y)} \end{aligned}$$

If $K(F_x, F_y)$ is near to 0, the effect of the noise is magnified.

Combined with the concept of the Wiener filter, the **equalizer** is modified as:

$$H(F_x, F_y) = \frac{1}{\frac{1}{K^*(F_x, F_y)} \frac{E\left(\left|Noise(F_x, F_y)\right|^2\right)}{E\left(\left|X(F_x, F_y)\right|^2\right)} + K(F_x, F_y)}$$

E : mean

$$H(F_x, F_y) = \frac{1}{\frac{C}{K^*(F_x, F_y)} + K(F_x, F_y)}$$

C is large when the SNR is small

C is small when the SNR is large

Implementation

$$X(F_x, F_y) = \text{fft2}(x[m, n])$$

$$K(F_x, F_y) = \text{fft2}(k_1[m, n])$$



$$k_1(m, n) = k(m, n) \quad \text{if } 0 \leq m \leq L, \quad 0 \leq n \leq L$$

$$k_1(M + m, n) = k(m, n) \quad \text{if } -L \leq m < 0, \quad 0 \leq n \leq L$$

$$k_1(m, N + n) = k(m, n) \quad \text{if } 0 \leq m \leq L, \quad -L \leq n < 0$$

$$k_1(M + m, N + n) = k(m, n) \quad \text{if } -L \leq m < 0, \quad -L \leq n < 0$$

$$k_1(M + m, N + n) = 0 \quad \text{otherwise}$$



(5) PCA and SVD

PCA (principal component analysis) 是資料分析和影像處理當中常用到的數學方法，用來分析資料的「主要成分」或是影像中物體的「主軸」。

它其實和各位同學在高中和大一線代所學的回歸線 (regressive line) 很類似。回歸線是用一條一維 (one-dimensional) 的直線來近似二維 (two-dimensional) 的資料，而 PCA 則是用 M -dimensional data 來近似 N -dimensional data，其中 M 小於等於 N

在講解 PCA 之前，先介紹什麼是 SVD (singular value decomposition)

我們在大一的時候，都已經學到該如何對於 $N \times N$ 的矩陣做 eigenvector -eigenvalue decomposition

那麼.....

當一個矩陣的 size 為 $M \times N$ 且 M 和 N 不相等時，我們該如何對它來做 eigenvector-eigenvalue decomposition?



SVD 的流程：

假設 \mathbf{A} 是一個 $M \times N$ 的矩陣。

(Step 1) 計算

$$\mathbf{B} = \mathbf{A}^H \mathbf{A}$$

$$\mathbf{C} = \mathbf{A} \mathbf{A}^H$$

如果只是要找 principal axis
C 和 U 的計算可省略

注意， \mathbf{B} 是 $N \times N$ 的矩陣，而 \mathbf{C} 是 $M \times M$ 的矩陣。上標 H 代表 Hermitian matrix，相當於做共軛轉置。

(Step 2) 接著，對 \mathbf{B} 和 \mathbf{C} 做 eigenvector-eigenvalue decomposition

$$\mathbf{B} = \mathbf{V} \mathbf{D} \mathbf{V}^{-1}$$

$$\mathbf{C} = \mathbf{U} \mathbf{\Lambda} \mathbf{U}^{-1}$$

其中 \mathbf{V} 的每一個 column 是 \mathbf{B} 的 eigenvector (with normalization)， \mathbf{U} 的每一個 column 是 \mathbf{C} 的 eigenvector (with normalization)， $\mathbf{\Lambda}$ 和 \mathbf{D} 都是對角矩陣， $\mathbf{\Lambda}$ 和 \mathbf{D} 對角線上的 entries 是 \mathbf{B} 和 \mathbf{C} 的 eigenvalues。並假設 eigenvectors 根據 eigenvalues 的大小排序 (由大到小)

Note: 值得注意的是，由於 $\mathbf{B} = \mathbf{B}^H$ 且 $\mathbf{C} = \mathbf{C}^H$ ，所以 \mathbf{B} 和 \mathbf{C} 的 eigenvectors 皆各自形成一個 orthogonal set。經過適當的 normalization 使得 \mathbf{U} 和 \mathbf{V} 的 column 自己和自己的內積為 1 之後， $\mathbf{U}^{-1} = \mathbf{U}^H$ 和 $\mathbf{V}^{-1} = \mathbf{V}^H$ 將滿足。因此， \mathbf{B} 和 \mathbf{C} 可以表示成

$$\mathbf{B} = \mathbf{V} \mathbf{D} \mathbf{V}^H$$

$$\mathbf{C} = \mathbf{U} \mathbf{\Lambda} \mathbf{U}^H$$

注意， \mathbf{V} 和 \mathbf{U} 是 unitary matrix

(Step 3) 計算

$$\mathbf{S}_1 = \mathbf{U}^H \mathbf{A} \mathbf{V} \quad \mathbf{S} = |\mathbf{S}_1| \quad \text{取絕對值}$$

\mathbf{S} 是一個 $M \times N$ 的矩陣，只有在 $\mathbf{S}[n, n]$ ($n = 1, 2, \dots, \min(M, N)$) 的地方不為 0

(Step 4) 若 $\mathbf{S}_1[n, n] < 0$ ，改變 \mathbf{U} 第 n 個 column 的正負號

即完成 SVD

$$\mathbf{A} = \mathbf{U} \mathbf{S} \mathbf{V}^H$$

\mathbf{A} 也可以表示為

$$\mathbf{A} = \lambda_1 \mathbf{u}_1 \mathbf{v}_1^T + \lambda_2 \mathbf{u}_2 \mathbf{v}_2^T + \dots + \lambda_k \mathbf{u}_k \mathbf{v}_k^T$$

其中 $\lambda_n = \mathbf{S}[n, n]$, $k = \min(M, N)$

註：Matlab 有內建的 `svd` 指令可以計算 SVD

從 SVD 到 PCA (principal component analysis , 主成份分析)

$$\mathbf{A} = \lambda_1 \mathbf{u}_1 \mathbf{v}_1^T + \lambda_2 \mathbf{u}_2 \mathbf{v}_2^T + \cdots + \lambda_k \mathbf{u}_k \mathbf{v}_k^T \quad k = \min(M, N)$$

若 $\lambda_1 \geq \lambda_2 \geq \lambda_3 \geq \cdots \geq \lambda_k$

$\lambda_1 \mathbf{u}_1 \mathbf{v}_1^T$ 是 \mathbf{A} 矩陣的最主要的成份

$\lambda_2 \mathbf{u}_2 \mathbf{v}_2^T$ 是 \mathbf{A} 矩陣的第二主要的成份

:

$\lambda_k \mathbf{u}_k \mathbf{v}_k^T$ 是 \mathbf{A} 矩陣的最不重要的成份

若為了壓縮或是去除雜訊的考量，可以選擇 $h < k$ ，使得 \mathbf{A} 可以近似成

$$\mathbf{A} \cong \lambda_1 \mathbf{u}_1 \mathbf{v}_1^T + \lambda_2 \mathbf{u}_2 \mathbf{v}_2^T + \cdots + \lambda_h \mathbf{u}_h \mathbf{v}_h^T$$



PCA 的流程

假設現在有 M 筆資料，每一筆資料 為 N dimension

$$\mathbf{g}_1 = [f_{1,1} \ f_{1,2}, \dots, f_{1,N}]$$

$$\mathbf{g}_2 = [f_{2,1} \ f_{2,2}, \dots, f_{2,N}]$$

⋮

$$\mathbf{g}_M = [f_{M,1} \ f_{M,2}, \dots, f_{M,N}]$$

(Step 1) 扣掉平均值，形成新的 data

$$\mathbf{d}_m = [e_{m,1} \ e_{m,2} \ \cdots \ e_{m,N}] \quad m = 1, 2, \dots, M$$

$$\text{其中 } e_{m,n} = f_{m,n} - \tilde{f}_n, \quad \tilde{f}_n = \frac{1}{M} \sum_{m=1}^M f_{m,n}$$

(Step 2) 形成 $M \times N$ 的矩陣 \mathbf{A}

$$\mathbf{A} \text{ 的第 } m \text{ 個 row 為 } \mathbf{d}_m, \quad m = 1, 2, \dots, M$$

(Step 3) 對 \mathbf{A} 做 SVD 分解

$$\begin{aligned}\mathbf{A} &= \mathbf{U}\mathbf{S}\mathbf{V}^H \\ &= \lambda_1 \mathbf{u}_1 \mathbf{v}_1^T + \lambda_2 \mathbf{u}_2 \mathbf{v}_2^T + \cdots + \lambda_k \mathbf{u}_k \mathbf{v}_k^T\end{aligned}\quad k = \min(M, N)$$

$$\lambda_1 \geq \lambda_2 \geq \lambda_3 \geq \cdots \geq \lambda_k$$

(Step 4) 將 \mathbf{A} 近似成

$$\mathbf{A} \cong \lambda_1 \mathbf{u}_1 \mathbf{v}_1^T + \lambda_2 \mathbf{u}_2 \mathbf{v}_2^T + \cdots + \lambda_h \mathbf{u}_h \mathbf{v}_h^T$$

則每一筆資料可以近似為

$$g_{\mathbf{m}} \cong \lambda_1 u_1[m] \mathbf{v}_1^T + \lambda_2 u_2[m] \mathbf{v}_2^T + \cdots + \lambda_h u_h[m] \mathbf{v}_h^T + [\tilde{f}_1 \quad \tilde{f}_2 \quad \cdots \quad \tilde{f}_N]$$

除了平均值 $[\tilde{f}_1 \quad \tilde{f}_2 \quad \cdots \quad \tilde{f}_N]$ 之外

\mathbf{v}_1^T 是資料的最主要成分， \mathbf{v}_2^T 是資料的次主要成分，
 \mathbf{v}_3^T 是資料的第三主要成分，以此類推


PCA 的例子

假設在一個二維的空間中，有5個點，
座標分別是

$(7,8)$, $(9,8)$, $(10, 10)$, $(11,12)$, $(13,12)$

$M = 5$, $N = 2$

試求這五個點的 PCA (即回歸線)



(Step 1) 將這五個座標點減去平均值 $(10, 10)$

$(-3, -2)$, $(-1, -2)$, $(0, 0)$, $(1, 2)$, $(3, 2)$

(Step 2) 形成 5x2 的 matrix

$$\mathbf{A} = \begin{bmatrix} -3 & -2 \\ -1 & -2 \\ 0 & 0 \\ 1 & 2 \\ 3 & 2 \end{bmatrix}$$

$$\mathbf{A} = \mathbf{U}\mathbf{S}\mathbf{V}^H$$

From page 39

$$\mathbf{U} = \begin{bmatrix} -0.6116 & 0.3549 & 0 & 0.0393 & 0.7060 \\ -0.3549 & -0.6116 & 0 & 0.7060 & -0.0393 \\ 0 & 0 & 1 & 0 & 0 \\ 0.3549 & 0.6116 & 0 & 0.7060 & -0.0393 \\ 0.6116 & -0.3549 & 0 & 0.0393 & 0.7060 \end{bmatrix}$$

$$\mathbf{S} = \begin{bmatrix} 5.8416 & 0 \\ 0 & 1.3695 \\ 0 & 0 \\ 0 & 0 \\ 0 & 0 \end{bmatrix}$$

$$\mathbf{V} = \begin{bmatrix} 0.7497 & -0.6618 \\ 0.6618 & 0.7497 \end{bmatrix}$$

主成分

次要成分

$$\mathbf{A} = 5.8416 \begin{bmatrix} -0.6116 \\ -0.3549 \\ 0 \\ 0.3549 \\ 0.6116 \end{bmatrix} \begin{bmatrix} 0.7497 & 0.6618 \end{bmatrix} + 1.3695 \begin{bmatrix} 0.3549 \\ -0.6116 \\ 0 \\ 0.6116 \\ -0.3549 \end{bmatrix} \begin{bmatrix} -0.6618 & 0.7497 \end{bmatrix}$$

(Step 4) 得到主成分 $[0.7497 \quad 0.6618]$

這五個座標點可以近似成


$$5.8416 \cdot u_m [0.7497 \quad 0.6618] + [10 \quad 10] \quad m = 1, 2, \dots, 5$$

$$u_1 = -0.6116, \quad u_2 = -0.3549, \quad u_3 = 0, \quad u_4 = 0.3549, \quad u_5 = 0.6116$$

回歸線

$$[10 \quad 10] + c [0.7497 \quad 0.6618]$$

$$c \in (-\infty, \infty)$$



練習

(1) 選兩張大小一樣的圖，用 Fourier Transform 將一張圖的低頻成份和另一張圖的高頻成份複合起來

(2) 寫出對一個圖型做 erosion 三次，dilation 三次，opening (其中 erosion 和 dilation 皆三次)，closing (其中 erosion 和 dilation 皆三次) 的程式

(3) (a) 產生 blurred image

$$y[m, n] = x[m, n] * k[m, n] + \text{noise}[m, n]$$

其中 $k[m, n] = s \exp[-0.1 * (m^2 + n^2)]$, $-10 \leq m, n \leq 10$

noise 可由 rand 產生

(b) 用 equalizer 來由 $y[m, n]$ 還原 $x[m, n]$

試用二個不同的 C 值，和二個不同的雜訊大小


$$s = \frac{1}{\sum_{m=-10}^{10} \sum_{n=-10}^{10} e^{-0.1(m^2 + n^2)}}$$

(4) 對以下的資料做 PCA

(2, -1, 3), (-1, 3, 5), (0, 2, 4), (4, -2, -1), (1, 0, 4), (-2, 5, 5)

(5) 運用 Google 學術搜尋，找出以下的論文並閱讀，並畫出的流程圖

C. Harris and M. Stephens, “A combined corner and edge detector”, Proc. 4th Alvey Vision Conf., 1988, pp. 147-151.



α, β :
the variation along two axes